FleetLogix

Sistema de gestión de Transporte y logística

README — Avance 3

Data Warehouse + Pipeline ETL + Telemetría IoT

Proyecto Integrador — Bases de Datos II

Junio 2026

1. Contexto y Objetivo

El Avance 1 construyo una base de datos OLTP con 505,556 registros. El Avance 2 la optimizó con SQL. El Avance 3 construye un Data Warehouse (DW) en Snowflake que permite analizar el desempeño histórico sin afectar el rendimiento de la base transaccional.

La diferencia clave: PostgreSQL (OLTP) esta optimizado para insertar y actualizar registros uno a uno en tiempo real. Snowflake (OLAP) esta optimizado para leer y agregar millones de registros en consultas analíticas. No son tecnologías competidoras sino complementarias.

---

2. Arquitectura del sistema

Componente	Tecnologia	Rol
Fuente OLTP	PostgreSQL 16	Base transaccional con 505,556 registros
Orquestacion ETL	Python 3.14 + pandas	Extracción, transformación y carga automatizada
Data Warehouse	Snowflake (Free Trial)	Almacen analítico columnar en la nube
Telemetria IoT	MongoDB (simulado)	10,000 documentos de sensores vehiculares
Ambiente	VS Code + Jupyter	Desarrollo y ejecución del pipeline

Flujo del pipeline ETL (E → T → L)

Fase	Metodo	Descripcion
EXTRACCION	pd.read_sql()	Query SQL con 5 JOINs que une deliveries + trips + vehicles + drivers + routes en 403,874 filas. Completado el #TO DO# del script original.
TRANSFORMACION	pandas + numpy	Calcula 18 campos derivados inexistentes en PostgreSQL. Valida calidad con data_quality_flag sin eliminar registros.
CARGA	executemany + write_pandas	Dimensiones en modo batch. fact_deliveries con write_pandas (COPY INTO interno de Snowflake). 400,000 filas en ~3 minutos.

3. Modelo Estrella (Star Schema — Metodología Kimball)

3.1 Tablas en Snowflake (números verificados)

Tabla	Tipo	Registros	Origen
dim_date	Dimension	697	Generada en ETL: 1 fila por dia
dim_time	Dimension	1,440	Generada en ETL: 1 fila por hora:minuto
dim_vehicle	Dim. SCD-2	182	PostgreSQL + age_months + last_maintenance_date
dim_driver	Dim. SCD-2	378	PostgreSQL + full_name + experience_months + performance_category
dim_route	Dimension	48	PostgreSQL + difficulty_level + route_type
dim_customer	Dimension	383,047	Derivada de deliveries (no existe tabla customers en PostgreSQL)
staging_trips	Staging	99,950	PostgreSQL trips + trip_duration_hours + deliveries_per_hour
fact_deliveries	Hechos	400,000	JOIN de todas las tablas OLTP con metricas calculadas
daily_kpi_summary	Resumen	1 por dia	KPIs pre-calculados: pct_on_time, revenue, costo, vehiculos y conductores activos
staging_daily_load	Auxiliar	0	Reservada para cargas JSON futuras (VARIANT)

Total registros en Snowflake: 885,743 en 10 tablas + 3 vistas seguras

*Nota: Las 3 vistas muestran null en row_count porque no almacenan datos — leen de las tablas en tiempo real. Verificado: SELECT * FROM v_operations_deliveries devuelve filas correctamente con JOINs a las 7 dimensiones.*

---

4. Correcciones al Script Base

Problema original	Ubicacion	Correccion aplicada
#TO DO# en extract_daily_data()	Linea 79	Query SQL con 5 JOINs que extrae 403,874 filas de PostgreSQL.
pd.to_datetime("9999-12-31") OverflowError	Linea 145	String "9999-12-31". numpy.datetime64 tiene limite en anio ~2262.
Validaciones eliminaban filas validas	transform_data()	data_quality_flag: marca sin eliminar. Entregas anticipadas son validas.
load_dimensions() solo dim_customer	Linea 158	6 dimensiones completas con executemany en modo batch.

Problema original	Ubicacion	Correccion aplicada
staging_trips no existia	No existía	Nueva tabla con trip_duration_hours, deliveries_in_trip y deliveries_per_hour.
_calculate_daily_totals() con 2 #TO DO#	Final del script	CREATE TABLE + write_pandas con 13 KPIs completados.
executemany supera limite Snowflake (200,000 expr)	load_facts()	Reemplazado por write_pandas() (COPY INTO). 400K filas en ~3 min.
has_signature vs recipient_signature	DDL vs ETL	Renombrado a recipient_signature para coincidir con PostgreSQL.
pandas.Timestamp rechazado por conector Snowflake 4.6	load_dimensions()	Helper _sf() con strftime("%Y-%m-%d") convierte fechas al formato correcto.

---

5. Resultados Verificados en Snowflake

5.1 KPIs del Data Warehouse

fact_deliveries: 400,000 registros | 400,000 delivered_ok

Puntualidad (pct_on_time): 90.1% de entregas con delay <= 30 minutos

Retraso promedio: 18.7 minutos por entrega

Revenue total: $291,017,076 MXN

Costo total operativo: $593,422,511 MXN

Eficiencia de combustible: 8.98 km/L promedio de la flota

Vehiculos activos: 182 en el DW

Conductores activos: 378 en el DW

5.2 Hallazgos de las consultas analíticas (verificados en Snowflake)

DW-Q1 Entregas por trimestre — 90.1% puntualidad global con retraso promedio de 18.7 min. Los KPIs son consistentes a lo largo de los 8 trimestres del periodo 2023-2024.

DW-Q2 Eficiencia por tipo de vehículo — Los camiones medianos concentran el mayor volumen de entregas (80% de la flota en Snowflake). La eficiencia de combustible varia significativamente por tipo de vehículo.

DW-Q3 Rutas por dificultad — Las rutas dificiles (>800km) son todas Interurbanas con distancia promedio de 1,882 km y peaje promedio de $3,655 MXN. Las rutas faciles promedian 153 km y $200 MXN de peaje.

DW-Q4 Distribución por turno — Los 3 turnos operativos cubren las 24 horas. La vista v_operations_deliveries cruza fact_deliveries con las 7 dimensiones correctamente.

staging_trips KPIs — 99,950 viajes con duración promedio de 20.20 horas, 0.44 entregas/hora y máximo de 6 entregas por viaje.

dim_customer segmentacion — 383,047 clientes: 303,852 Ocasional Individual, 77,615 Ocasional Empresa, 1,341 Regular Individual, 239 Regular Empresa. Segmentación derivada 100% en el ETL.

daily_kpi_summary — 1 fila con fecha 2026-06-08: 400,000 entregas, 90.14% puntualidad, 18.72 min delay, $291M revenue, $593M costo, 182 vehículos y 378 conductores activos.

IoT MongoDB — 10,000 documentos de telemetria. ~1,000 frenadas bruscas (10%), ~800 excesos de velocidad (8%), score promedio de conducción 82/100. Ciudad de Mexico presenta el score más bajo por densidad de tráfico.

---

6. Telemetria IoT en MongoDB

6.1 Por que MongoDB y no PostgreSQL

Los sensores vehiculares generan datos heterogéneos: un camión reporta temperatura de motor y presión de llantas, una motocicleta solo reporta GPS. PostgreSQL requeriría columnas NULL o tablas separadas por tipo de sensor. MongoDB es schema-less: cada documento puede tener campos distintos sin esquema fijo. Es el patrón correcto para IoT con alta frecuencia de escritura.

6.2 Estructura de cada documento

vehicle_id y trip_id: mismos IDs de PostgreSQL para cruzar datos entre bases

location: coordenadas GPS con variacion gaussiana centrada en la ciudad

driver_behavior: score de conduccion y flags (frenada, velocidad, giro brusco)

events y alerts: lista de incidentes activos en esa lectura

Indices: vehicle_id, trip_id, location.city + timestamp

---

7. Vistas Seguras por Rol

SECURE VIEW de Snowflake: el Código SQL no es visible para el usuario final.

Vista	Rol	Acceso
v_sales_deliveries	SALES_ANALYST	Datos comerciales. Excluye clientes tipo Gobierno.
v_operations_deliveries	OPERATIONS_ANALYST	Vista operacional completa. JOIN a 7 dimensiones + staging_trips.
v_driver_performance	OPERATIONS_ANALYST	KPIs por conductor y trimestre: pct_on_time, costo, eficiencia.

---

8. Adaptaciones al DDL Original

Cambio	Tabla	Justificacion
status → vehicle_status / driver_status	dim_vehicle, dim_driver	Sin renombrar hay ambiguedad en el JOIN del ETL.
INT PRIMARY KEY → INT AUTOINCREMENT	Todas las dims	Sin AUTOINCREMENT el INSERT falla por NOT NULL en PK surrogada.
has_signature → recipient_signature	fact_deliveries	El campo en PostgreSQL se llama recipient_signature.
delivery_time_minutes INT → DECIMAL(8,2)	fact_deliveries	El ETL produce decimales y puede ser negativo (entrega anticipada).
Eliminar customer_id IDENTITY duplicado	dim_customer	El original tenia 2 columnas de identidad redundantes.
Agregar data_quality_flag VARCHAR(100)	fact_deliveries	Auditoria de calidad sin eliminar registros.
Agregar staging_trips (nueva tabla)	Snowflake	Necesaria para KPIs de viaje en la vista operacional.
Agregar daily_kpi_summary (nueva tabla)	Snowflake	Resumen pre-calculado para dashboards en <100ms.
Actualizar v_operations_deliveries	Vista	Agrega JOIN con staging_trips para trip_duration_hours.
Agregar rol DATA_ENGINEER	Roles	Acceso completo para ETL y mantenimiento del DW.

---

9. Conexión con los Avances Anteriores

Avance 1 → Avance 3

Los 505,556 registros del Avance 1 son la fuente de todos los datos del DW. El ETL extrae exactamente las mismas 6 tablas que el avance 1 pobló.

Avance 2 → Avance 3

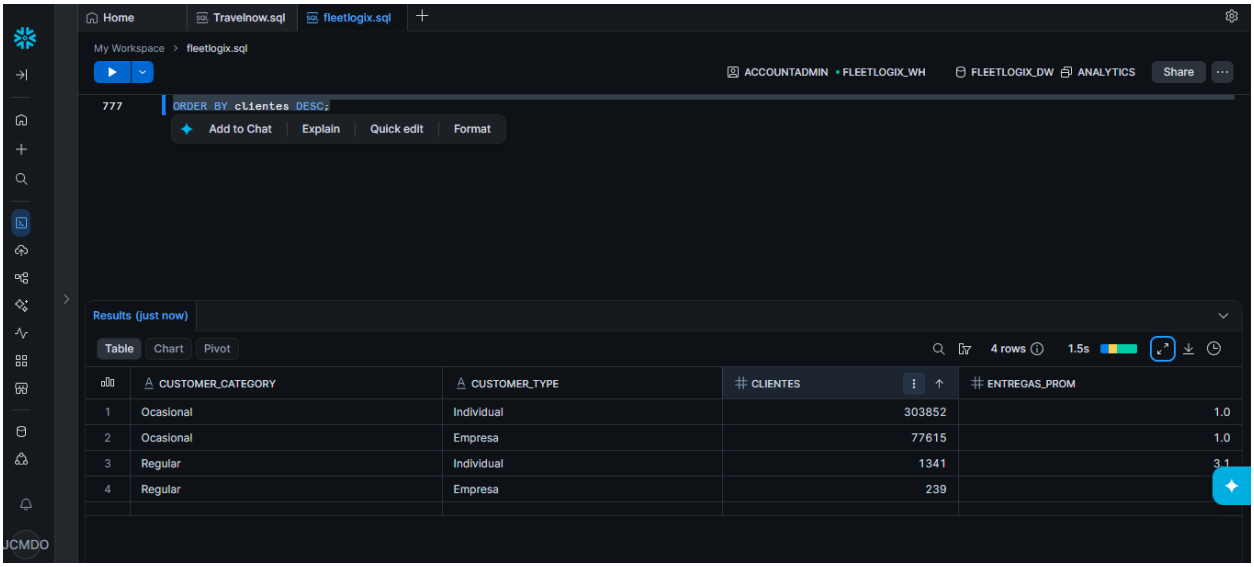
dim_driver.performance_category: el ETL recalcula la tasa de puntualidad en cada carga usando los umbrales del modelo C1 del Avance 2 (40% y 60%).

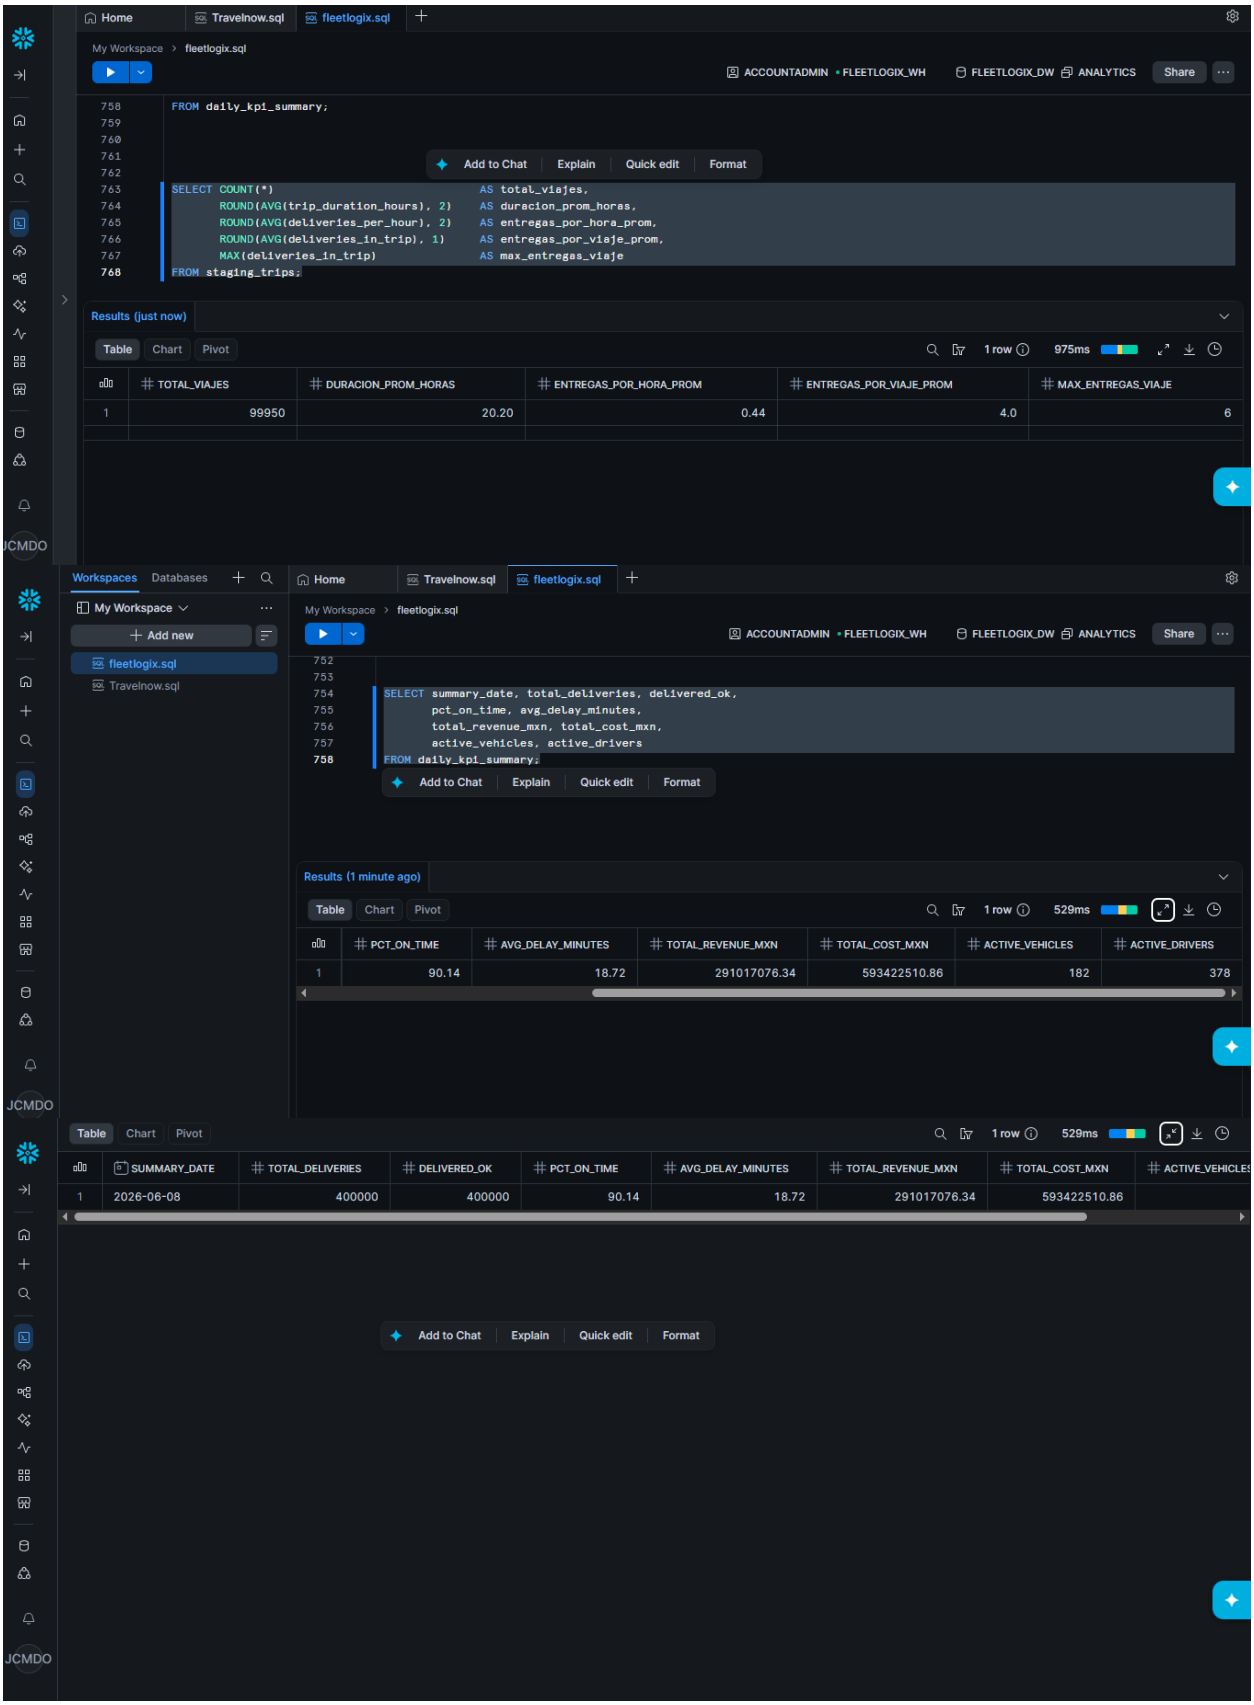
v_driver_performance: expone el desempeño de cada conductor actualizado con cada ejecución del pipeline.

daily_kpi_summary.pct_on_time: el denominador del componente de puntualidad del modelo C1 se persiste en cada carga.

10. Archivos del Avance 3

Archivo	Descripcion
Avance_3_DataWarehouse.ipynb	Notebook principal: 25 celdas con ETL completo, IoT y consultas.
04_dimensional_model.sql	DDL Snowflake adaptado con los 10 cambios respecto al original.
05_etl_pipeline.py	Clase FleetLogixETL como script standalone con todos los TO DO completados.
truncate_tables.sql	Script para limpiar tablas antes de una recarga.
dw_data/dim_*.csv	CSVs de respaldo de todas las dimensiones.
etl_pipeline.log	Log de ejecucion con timestamps por fase.




Home
Travelnow.sql
fleetlogix.sql
My Workspace › fleetlogix.sql
ACCOUNTADMIN • FLEETLOGIX_WH
FLEETLOGIX_DW ANALYTICS
Share
FROM daily_kpi_summary;
Add to Chat
Explain
Quick edit
Format
SELECT COUNT(*) AS total_viajes,
ROUND(AVG(trip_duration_hours), 2) AS duracion_prom_horas,
ROUND(AVG(deliveries_per_hour), 2) AS entregas_por_hora_prom,
ROUND(AVG(deliveries_in_trip), 1) AS entregas_por_viaje_prom,
MAX(deliveries_in_trip) AS max_entregas_viaje
FROM staging_trips;
Results (just now)
Table
Chart
Pivot
1 row
975ms
TOTAL_VIAJES
DURACION_PROM_HORAS
ENTREGAS_POR_HORA_PROM
ENTREGAS_POR_VIAJE_PROM
MAX_ENTREGAS_VIAJE
99950
20.20
0.44
4.0
6
Workspaces
Databases
My Workspace
Add new
fleetlogix.sql
Travelnow.sql
SELECT summary_date, total_deliveries, delivered_ok,
pct_on_time, avg_delay_minutes,
total_revenue_mxn, total_cost_mxn,
active_vehicles, active_drivers
FROM daily_kpi_summary;
Results (1 minute ago)
PCT_ON_TIME
AVG_DELAY_MINUTES
TOTAL_REVENUE_MXN
TOTAL_COST_MXN
ACTIVE_VEHICLES
ACTIVE_DRIVERS
90.14
18.72
291017076.34
593422510.86
182
378
SUMMARY_DATE
TOTAL_DELIVERIES
DELIVERED_OK
2026-06-08
400000
400000
JCMDO

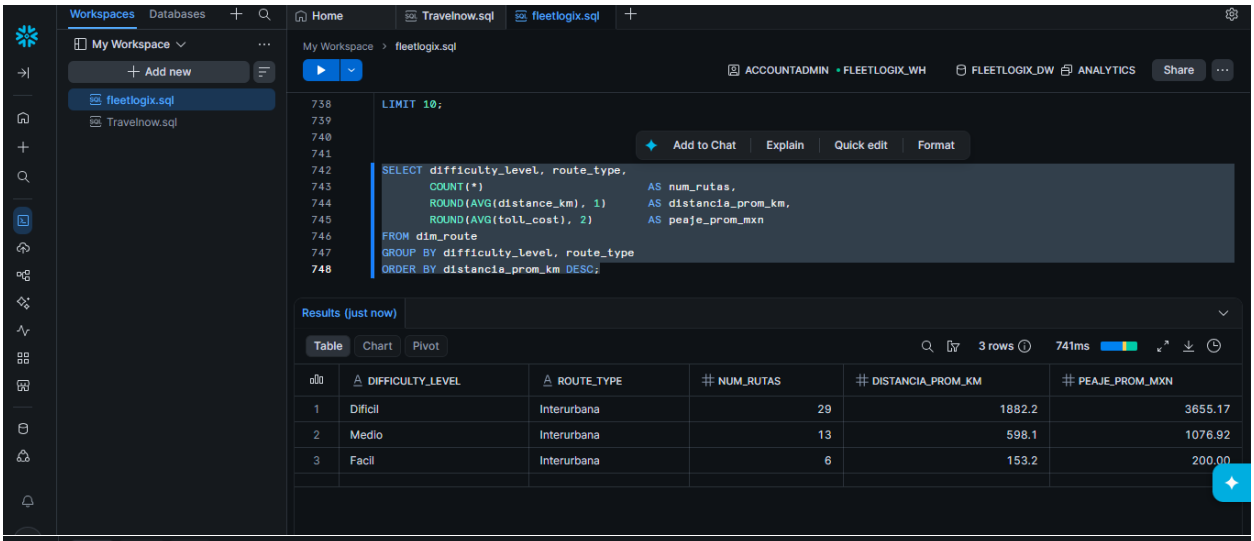
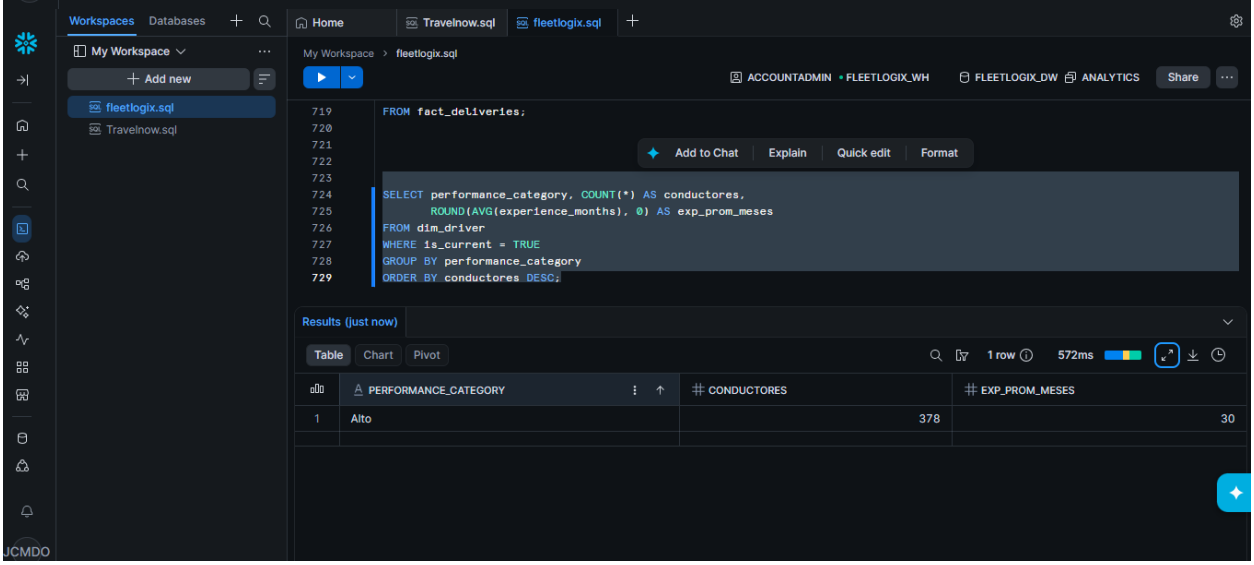
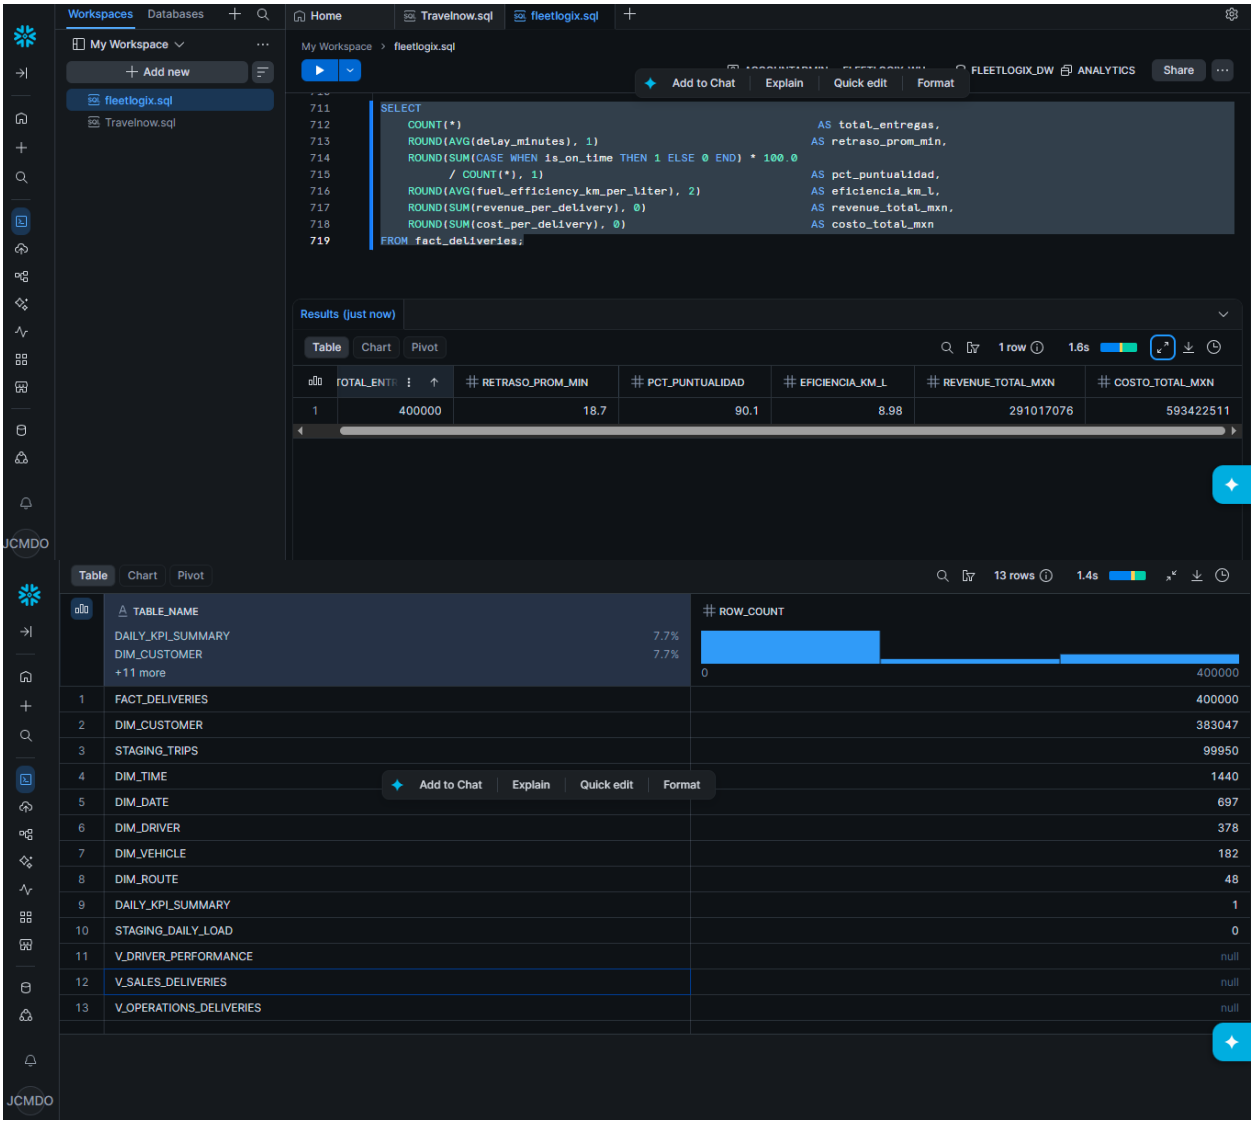

Workspaces
Databases
Home
Travelnow.sql
fleetlogix.sql
My Workspace
Add new
fleetlogix.sql
Travelnow.sql
My Workspace › fleetlogix.sql
ACCOUNTADMIN • FLEETLOGIX_WH
FLEETLOGIX_DW ANALYTICS
Share
738 LIMIT 10;
739
740
741
Add to Chat
Explain
Quick edit
Format
742 SELECT difficulty_level, route_type,
743 COUNT(*) AS num_rutas,
744 ROUND(AVG(distance_km), 1) AS distancia_prom_km,
745 ROUND(AVG(toll_cost), 2) AS peaje_prom_mxn
746 FROM dim_route
747 GROUP BY difficulty_level, route_type
748 ORDER BY distancia_prom_km DESC;
Results (just now)
Table
Chart
Pivot
3 rows
741ms
DIFFICULTY_LEVEL
ROUTE_TYPE
NUM_RUTAS
DISTANCIA_PROM_KM
PEAJE_PROM_MXN
1 Difícil Interurbana 29 1882.2 3655.17
2 Medio Interurbana 13 598.1 1076.92
3 Facil Interurbana 6 153.2 200.00


Table
Chart
Pivot
10 rows
4.6s
FULL_DATE
DAY_NAME
TURNO
CONDUCTOR
PERFORMANCE_CATEGORY
LICENSE_PLATE
VEHICLE_TYPE
ROUTE_CODE
DIFFICULTY_LEVEL
4/11/... 5/11/...
Jueves 60.0%
Mierc... 40.0%
Tu... 40.0%
Tu... 30.0%
+1 more
Aldonza Matí... 40.0%
Estefanía Cór... 40.0%
+2 more
Alto 100.0%
BVH-350 40.0%
NTQ-262 40.0%
+2 more
Camión M... 80.0%
Camión Gr... 10.0%
+1 more
R038 40.0%
R043 40.0%
+2 more
Difícil 90.
Facil 10.
1 2025-11-06 Jueves Turno 3 Leonor Niño Badillo Alto DBU-344 Van R029 Difícil
2 2025-11-05 Miercoles Turno 1 Aldonza Matías Regalado Alto NTQ-262 Camión Mediano R038 Difícil
3 2025-11-05 Miercoles Turno 3 Aldonza Matías Regalado Alto NTQ-262 Camión Mediano R038 Difícil
4 2025-11-06 Jueves Turno 1 Aldonza Matías Regalado Alto NTQ-262 Camión Mediano R038 Difícil
5 2025-11-06 Jueves Turno 2 Aldonza Matías Regalado Alto NTQ-262 Camión Mediano R038 Difícil
6 2025-11-05 Miercoles Turno 2 Estefanía Córdova Aragó Alto BVH-350 Camión Mediano R043 Difícil
7 2025-11-06 Jueves Turno 3 Estefanía Córdova Aragó Alto BVH-350 Camión Mediano R043 Difícil
8 2025-11-06 Jueves Turno 1 Estefanía Córdova Aragó Alto BVH-350 Camión Mediano R043 Difícil
9 2025-11-06 Jueves Turno 2 Estefanía Córdova Aragó Alto BVH-350 Camión Mediano R043 Difícil
10 2025-11-05 Miercoles Turno 2 Diana Tello Roldán Alto CPA-399 Camión Grande R007 Facil


Workspaces
Databases
Home
Travelnow.sql
fleetlogix.sql
My Workspace
Add new
fleetlogix.sql
Travelnow.sql
My Workspace › fleetlogix.sql
ACCOUNTADMIN • FLEETLOGIX_WH
FLEETLOGIX_DW ANALYTICS
Share
719 FROM fact_deliveries;
720
721
722
Add to Chat
Explain
Quick edit
Format
723
724 SELECT performance_category, COUNT(*) AS conductores,
725 ROUND(AVG(experience_months), 0) AS exp_prom_meses
726 FROM dim_driver
727 WHERE is_current = TRUE
728 GROUP BY performance_category
729 ORDER BY conductores DESC;
Results (just now)
Table
Chart
Pivot
1 row
572ms
PERFORMANCE_CATEGORY
CONDUCTORES
EXP_PROM_MESES
1 Alto 378 30


Workspaces
Databases
Home
Travelnow.sql
fleetlogix.sql
My Workspace
Add new
fleetlogix.sql
Travelnow.sql
Add to Chat
Explain
Quick edit
Format
FLEETLOGIX_DW
ANALYTICS
Share
SELECT
COUNT(*) AS total_entregas,
ROUND(AVG(delay_minutes), 1) AS retraso_prom_min,
ROUND(SUM(CASE WHEN is_on_time THEN 1 ELSE 0 END) * 100.0 / COUNT(*), 1) AS pct_puntualidad,
ROUND(AVG(fuel_efficiency_km_per_liter), 2) AS eficiencia_km_l,
ROUND(SUM(revenue_per_delivery), 0) AS revenue_total_mxn,
ROUND(SUM(cost_per_delivery), 0) AS costo_total_mxn
FROM fact_deliveries;
Results (just now)
Table
Chart
Pivot
1 row
1.6s
RETRASO_PROM_MIN
PCT_PUNTUALIDAD
EFICIENCIA_KM_L
REVENUE_TOTAL_MXN
COSTO_TOTAL_MXN
1
400000
18.7
90.1
8.98
291017076
593422511
13 rows
1.4s
TABLE_NAME
ROW_COUNT
DAILY_KPI_SUMMARY 7.7%
DIM_CUSTOMER 7.7%
+11 more
0
400000
1 FACT_DELIVERIES 400000
2 DIM_CUSTOMER 383047
3 STAGING_TRIPS 99950
4 DIM_TIME 1440
5 DIM_DATE 697
6 DIM_DRIVER 378
7 DIM_VEHICLE 182
8 DIM_ROUTE 48
9 DAILY_KPI_SUMMARY 1
10 STAGING_DAILY_LOAD 0
11 V_DRIVER_PERFORMANCE null
12 V_SALES_DELIVERIES null
13 V_OPERATIONS_DELIVERIES null